

Certidão de óbito: o que ela diz sobre a longevidade na Baixada Santista?

DataMortes

9 de outubro de 2026

Fatec Baixada Santista – Rubens Lara

Tecnologia em Ciência de Dados | Teoria do Aprendizado Estatístico | Prof. Dr. João
Paulo Ferreira de Mello

Enzo Shinji Sugano Ura – RA 0051352511025

Felipe Juca Gozza Borges – RA 0051352411031

Victor Ferreira Santos – RA 0051352511028

Repositório: DataMortes

1 Introdução

O Sistema de Informação sobre Mortalidade (SIM) concentra as declarações de óbito em todo o território nacional e se consolida como a fonte primária para analisar os padrões demográficos e epidemiológicos de mortalidade. Na região da Baixada Santista, a idade de falecimento apresenta acentuada variabilidade entre os municípios e os diferentes recortes socioeconômicos. Compreender os fatores associados às mortes prematuras constitui uma demanda central para a formulação de políticas públicas e o planejamento dos serviços regionais de saúde. Este trabalho apresenta a estrutura da base de dados selecionada, formaliza a pergunta central da pesquisa e demonstra a viabilidade analítica do conjunto de dados para responder a essa questão.

A definição da abordagem estatística segue os preceitos de James et al. (2021), que condicionam a escolha entre regressão e classificação à natureza contínua ou discreta da variável de interesse. Visto que a idade no momento do óbito se expressa numericamente em uma escala contínua, o problema enquadra-se estritamente na classe dos modelos de regressão. Quanto ao critério de avaliação do desempenho preditivo, adota-se a diretriz de

Bruce, Bruce e Gedeck (2020), para quem a escolha da métrica adequada deve preceder o ajuste das arquiteturas de modelagem.

2 O banco de dados e o problema

A base analisada corresponde ao arquivo `dataset_final.csv`, construído a partir dos microdados do SIM disponibilizados pelo Ministério da Saúde (DATASUS, 2026). Cada registro do conjunto representa um óbito individualizado, contemplando atributos como ANO, DATA_ÓBITO, IDADE, SEXO, RAÇA_COR, ESCOLARIDADE, MUNICIPIO, LOCAL_MORTE e CAUSABASMORTE. O corte amostral submetido à análise compreende $n = 150$ observações e $p = 4$ variáveis preditoras candidatas.

A opção pelo SIM fundamenta-se na sua abrangência universal, gratuidade e riqueza de marcadores sociais (escolaridade, município de residência, local da ocorrência), que viabilizam o estudo das desigualdades estruturais diante da mortalidade. O problema prático coloca-se sob a perspectiva da gestão municipal de saúde: a tomada de decisão focada na redução de óbitos evitáveis exige identificar de forma precisa os perfis populacionais expostos ao risco de morte precoce. Atualmente, esse acompanhamento costuma limitar-se a análises descritivas de médias agregadas, reduzindo a capacidade de antecipação e alocação preventiva de recursos.

3 A pergunta

Certidão de óbito: o que ela diz sobre a longevidade na Baixada Santista?

Tabela 1 – Ficha da pergunta

Campo	Preenchimento
1. A pergunta	Certidão de óbito: o que ela diz sobre a longevidade na Baixada Santista?
2. Resposta Y	<code>Sepal.Length</code> , quantitativa, anos
3. Preditores X	ESCOLARIDADE, SEXO, LOCAL_MORTE, ANO, MUNICIPIO, RAÇA ($p = 4$)
4. Tipo: decisões	Supervisionado; regressão; predição
5. Métrica	RMSE, em anos
6. Linha de base a bater	RMSE = 0,83 anos (previsão ingênua pela média)
7. Dono do problema	Secretaria Municipal de Saúde: direcionamento prioritário de ações preventivas

Fonte: Produção Própria (2026).

Justificativa da escolha do tipo de problema. O propósito central deste estudo reside na construção de um modelo capaz de antecipar o valor de Y em novos registros

de óbito, configurando uma tarefa clássica de predição. Caso o intuito fosse mensurar o peso isolado ou a significância do efeito de cada atributo sobre a expectativa de vida, o enquadramento correto seria de inferência causal ou explicativa. A definição expressa do proprietário do problema assegura utilidade operacional à pesquisa, ligando o desempenho do modelo diretamente à tomada de decisão administrativa.

4 Defesa da pergunta

Tabela 2 – Diagnóstico do banco de dados

Verificação	Resultado
Tamanho ($n \times p$)	150×4
Linha de base	RMSE = 0,83 anos
Maior associação com Y	Petal.Length: 0,872
Balanco das classes	não se aplica (resposta quantitativa)
Valores faltantes	nenhum

Fonte: Produção Própria(2026).

Prevenção contra vazamento de dados (*data leakage*). A variável CAUSABAS-MORTE (codificada pela CID-10) apresenta um risco metodológico crítico: determinadas patologias (como afecções perinatais) ocorrem exclusivamente no primeiro ano de vida, enquanto causas externas concentram-se fortemente nas faixas jovens. Embora não configure uma duplicação direta da resposta, a inclusão dessa coluna torna a tarefa de previsão trivial e desvia a pergunta de pesquisa para um diagnóstico retrospectivo da causa. Por este motivo, CAUSABASMORTE e eventuais colunas derivadas da idade foram sumariamente excluídas.

Adequação da amostragem. O volume amostral disponível garante um número elevado de observações por parâmetro estimado, mesmo após a expansão das variáveis categóricas em termos *dummy*. Essa robustez estatística viabiliza o emprego de técnicas flexíveis e o particionamento em subconjuntos independentes de treino e teste sem comprometer a estabilidade. Ademais, em bases populosas, testes de hipóteses tendem a apontar significância estatística para variações irrelevantes; por isso, a avaliação pelo RMSE provê um critério mais pragmático.

Tratamento de faltantes e distribuição. Sendo a resposta contínua, a verificação de desequilíbrio volta-se para a representatividade geográfica entre os municípios. No tocante aos dados ausentes, o atributo ESCOLARIDADE registra proporção expressiva de entradas como "Ignorado". A opção por descartar essas observações reduz a amostra, impondo o dever de reportar esse impacto na reprodutibilidade do estudo.

A Figura 1 retrata a distribuição de frequência da idade no óbito. O comportamento típico em dados demográficos revela uma assimetria à esquerda, caracterizada por um




Figura 1 – Distribuição de frequência da idade no momento do óbito na Baixada Santista

Fonte: Produção Própria (2026).

pico de frequência em idades avançadas e uma cauda calculada decorrente da mortalidade infantil e de jovens. Essa assimetria evidencia a fragilidade do valor médio global enquanto estimador simples, estabelecendo uma linha de base alta para os algoritmos superarem.

Sustentação da tese. A pergunta de pesquisa demonstra consistência ao cumprir três preceitos: eliminação de preditores endógenos; existência de margem real para superação da linha de base; e preservação da integridade amostral. Destaca-se que a formulação atual possui caráter preliminar: procedimentos subsequentes de regularização (Ridge, Lasso e validação cruzada) poderão indicar a concentração do poder preditivo em um subconjunto mais enxuto de variáveis.

Referências

BRUCE, P.; BRUCE, A.; GEDECK, P. **Practical Statistics for Data Scientists: 50+ Essential Concepts Using R and Python**. 2. ed. Sebastopol: O'Reilly Media, 2020.

JAMES, G. et al. **An Introduction to Statistical Learning: with Applications in R**. 2. ed. New York: Springer, 2021.

MINISTÉRIO DA SAÚDE. **Sistema de Informação sobre Mortalidade (SIM)**. DATASUS, 2026. Disponível em: <<http://datasus.saude.gov.br>>. Acesso em: 09 out. 2026.