"Certidão de óbito: o que ela diz sobre a longevidade na Baixada Santista?"

DataMortes

16 de outubro de 2026

Fatec Baixada Santista – Rubens Lara
Tecnologia em Ciência de Dados | Teoria do Aprendizado Estatístico | Prof. Dr. João Paulo Ferreira de Mello

Enzo Shinji Sugano Ura – RA 0051352511025
Felipe Juca Gozza Borges – RA 0051352411031
Victor Ferreira Santos – RA 0051352511028

Repositório: `DataMortes`

1 Introdução

O Sistema de Informação sobre Mortalidade (SIM) concentra as declarações de óbito em todo o território nacional e se consolida como a fonte primária para analisar os padrões demográficos e epidemiológicos de mortalidade. Na região da Baixada Santista, a idade de falecimento apresenta acentuada variabilidade entre os municípios e os diferentes recortes socioeconômicos. Compreender os fatores associados às mortes prematuras constitui uma demanda central para a formulação de políticas públicas e o planejamento dos serviços regionais de saúde. Este trabalho apresenta a estrutura da base de dados selecionada, formaliza a pergunta central da pesquisa e demonstra a viabilidade analítica do conjunto de dados para responder a essa questão.

A definição da abordagem estatística segue os preceitos de James et al. (2021), que condicionam a escolha entre regressão e classificação à natureza quantitativa ou qualitativa da variável de interesse. Visto que a idade no momento do óbito se expressa numericamente em uma escala contínua, o problema enquadra-se estritamente na classe dos

modelos de regressão. Quanto ao critério de avaliação do desempenho preditivo, adota-se o erro quadrático médio da raiz (RMSE), métrica usual para respostas quantitativas (BRUCE; BRUCE; GEDECK, 2020), definida antes do ajuste dos modelos para que não seja escolhida a posteriori em favor do modelo vencedor.

2 O banco de dados e o problema

A base analisada corresponde ao arquivo `dataset_final.csv`, construído a partir dos microdados do SIM disponibilizados pelo Ministério da Saúde (MINISTÉRIO DA SAÚDE, 2026), referentes aos anos de 2020 a 2024. Cada registro do conjunto representa um óbito individualizado, contemplando atributos como ANO, DATA DE ÓBITO, IDADE, SEXO, RAÇA, ESCOLARIDADE, MUNICIPIO, LOCAL_MORTE, OCUP e CAUSA BASICA DA MORTE. A base original reúne 474.651 registros; após o tratamento dos dados ausentes (Seção 4), o corte amostral submetido à análise compreende $n = 458.897$ observações e $p = 6$ variáveis preditoras candidatas.

A opção pelo SIM fundamenta-se na sua abrangência universal, gratuidade e riqueza de marcadores sociais (escolaridade, município de residência, local da ocorrência), que viabilizam o estudo das desigualdades estruturais diante da mortalidade. O problema prático coloca-se sob a perspectiva da gestão municipal de saúde: a tomada de decisão focada na redução de óbitos evitáveis exige identificar de forma precisa os perfis populacionais expostos ao risco de morte precoce. Atualmente, esse acompanhamento costuma limitar-se a análises descritivas de médias agregadas, reduzindo a capacidade de antecipação e alocação preventiva de recursos.

3 A pergunta

Certidão de óbito: o que ela diz sobre a longevidade na Baixada Santista?

Justificativa da escolha do tipo de problema. O propósito central deste estudo reside na construção de um modelo capaz de antecipar o valor de Y em novos registros de óbito, configurando uma tarefa clássica de predição. Caso o intuito fosse mensurar o peso isolado ou a significância do efeito de cada atributo sobre a expectativa de vida, o enquadramento correto seria o de inferência estatística. A definição expressa do proprietário do problema assegura utilidade operacional à pesquisa, ligando o desempenho do modelo diretamente à tomada de decisão administrativa.

4 Defesa da pergunta

Prevenção contra vazamento de dados (*data leakage*). A variável CAUSA BASICA DA MORTE (codificada pela CID-10) apresenta um risco metodológico crítico:

Tabela 1 – Ficha da pergunta

Campo	Preenchimento
1. A pergunta	Certidão de óbito: o que ela diz sobre a longevidade na Baixada Santista?
2. Resposta Y	IDADE, quantitativa, anos
3. Preditores X	ESCOLARIDADE, SEXO, LOCAL_MORTE, ANO, MUNICIPIO, RAÇA ($p = 6$)
4. Tipo: decisões	Supervisionado; regressão; predição
5. Métrica	RMSE, em anos
6. Linha de base a bater	RMSE = 16,90 anos (previsão ingênua pela média)
7. Dono do problema	Secretaria Municipal de Saúde: direcionamento prioritário de ações preventivas

Fonte: Elaborada pelo autor.

Tabela 2 – Diagnóstico do banco de dados

Verificação	Resultado
Tamanho ($n \times p$)	458.897×6
Linha de base	RMSE = 16,90 anos
Maior associação com Y	MUNICIPIO: razão de correlação $\eta = 0{,}267$ ($\eta^2 = 0{,}071$)
Balanço das classes	Não se aplica (variável resposta quantitativa)
Valores faltantes (base original)	ESCOLARIDADE: 14.127 (4.133 em branco e 9.994 "Ignorado"); RAÇA: 1.787; IDADE: 227; demais preditores: nenhum

Fonte: Elaborada pelo autor.

determinadas patologias (como afecções originadas no período perinatal) ocorrem quase exclusivamente no primeiro ano de vida, enquanto causas externas concentram-se fortemente nas faixas jovens. Embora não configure uma duplicação direta da resposta, a inclusão dessa coluna torna a previsão artificialmente fácil e desvia a pergunta de pesquisa para um diagnóstico retrospectivo da causa. Por este motivo, CAUSA BASICA DA MORTE e eventuais colunas derivadas da idade foram excluídas dos preditores.

Adequação da amostragem. Com $n = 458.897$ observações para $p = 6$ preditoras, o volume amostral garante um número elevado de observações por parâmetro estimado, mesmo após a expansão das variáveis categóricas em termos *dummy*. Essa robustez estatística viabiliza o emprego de técnicas flexíveis e o particionamento em subconjuntos independentes de treino e teste sem comprometer a estabilidade. Ademais, em bases populosas, testes de hipóteses tendem a apontar significância estatística para variações irrelevantes; por isso, a avaliação pelo RMSE, expressa em anos, provê um critério mais pragmático.

Tratamento de faltantes e distribuição. Sendo a resposta contínua, a verificação

de desequilíbrio volta-se para a representatividade geográfica entre os municípios: Santos concentra 42,1% dos registros originais e Bertioga, 1,7%, o que deve ser considerado na interpretação dos resultados. No tocante aos dados ausentes, o atributo ESCOLARIDADE registra 14.127 entradas em branco ou "Ignorado" (3,0% da base). Foram descartados esses registros e também os que não informam IDADE, RAÇA ou SEXO, o que reduz a amostra de 474.651 para 458.897 observações (perda de 3,3%); esse impacto é reportado para garantir a reprodutibilidade do estudo.

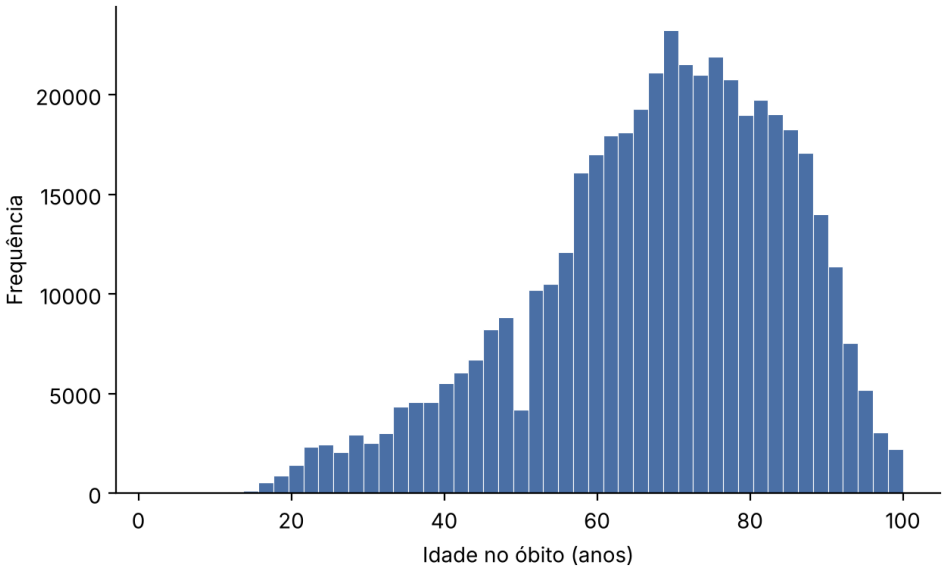


Figura 1 – Distribuição de frequência da idade no óbito

Fonte: Elaborada pelo autor com base nos dados do SIM (2026).

A Figura 1 retrata a distribuição de frequência da idade no óbito. Observa-se assimetria à esquerda (mediana de 70 anos, média de 67,9 e desvio-padrão de 16,9), com pico em idades avançadas e uma cauda alongada decorrente da mortalidade infantil e de jovens. Essa assimetria evidencia a fragilidade do valor médio global enquanto estimador simples, estabelecendo uma linha de base com margem de melhoria para os algoritmos.

Sustentação da tese. A pergunta de pesquisa demonstra consistência ao cumprir três preceitos: eliminação de preditores que vazam informação da resposta; existência de margem para superação da linha de base (as razões de correlação η^2 individuais variam de 0,002, para ANO, a 0,071, para MUNICIPIO, indicando sinal modesto em cada preditor); e preservação da integridade amostral (perda de apenas 3,3% dos registros). Destaca-se que a formulação atual possui caráter preliminar: procedimentos subsequentes de regularização (Ridge, Lasso e validação cruzada) poderão indicar a concentração do poder preditivo em um subconjunto mais enxuto de variáveis.

REFERÊNCIAS

BRUCE, P.; BRUCE, A.; GEDECK, P. **Practical Statistics for Data Scientists**: 50+ Essential Concepts Using R and Python. 2. ed. Sebastopol: O'Reilly Media, 2020.

JAMES, G. et al. **An Introduction to Statistical Learning**: with Applications in R. 2. ed. New York: Springer, 2021.

MINISTÉRIO DA SAÚDE. **Sistema de Informação sobre Mortalidade (SIM)**. DATASUS, 2026. Disponível em: <http://datasus.saude.gov.br>. Acesso em: [inserir data de acesso].